

MediFlow · Kit de datos

Versión 0.1

Cómo se relacionan el banco clínico, los medicamentos y el catálogo CIE-10, y cómo se construye el conjunto de prueba

Este documento conecta todo lo necesario para armar el conjunto de prueba: qué cuadro clínico usa cada documento, qué medicamentos lleva, con qué código CIE-10 se valida y qué respuesta esperamos del agente. Todo está en los archivos de **evals/generator/data/**.

El **conjunto de prueba** tiene 50 elementos: 30 documentos que escribe el equipo, 12 imágenes degradadas que salen de algunos de esos documentos y 8 recetas manuscritas fotografiadas. En las tablas, **GS** identifica a los documentos del plan, del GS-01 al GS-30, y **M** a las recetas manuscritas, de la M1 a la M8.

DECISIÓN PENDIENTE DEL EQUIPO. Antes de escribir los documentos hay que elegir entre dos opciones para la regla de urgencia, A o B. Cuatro etiquetas del plan dependen de esa elección. Está explicada en la sección **Decisión pendiente: regla de urgencia por tipo de documento**.

Cómo se conecta todo




Tabla de referencia	Lo produce un script	Lo hace el equipo a mano	Fuente pública externa	El agente
La línea discontinua hacia el agente indica que consulta esa tabla en cada documento que procesa, también en producción. Lo que tiene borde discontinuo se incorpora en la siguiente versión.				

Para qué sirve cada archivo

Archivo	Para qué sirve	Quién lo usa	Estado
banco_clinico.csv	Materia prima de los documentos de prueba: el contenido clínico de cada cuadro, con su código, hallazgos, conclusión y medicamentos	Quien escribe los documentos de prueba. El agente nunca lo lee	Listo
medicamentos.csv	Rango de dosis y marca de alto riesgo de cada medicamento	El agente, para validar la dosis de cada receta. También quien escribe las recetas de prueba	Falta comparar cada rango con el prospecto de la ANMAT
cie10.csv	Catálogo de códigos de diagnóstico válidos	El agente, para comprobar que el código que sugiere existe	Códigos listos. El texto que describe cada código se redactó sin copiarlo de la tabla oficial: falta reemplazarlo por el de la tabla CIE10 de SISPRO
rules.yaml	Reglas de decisión: umbrales, urgencias, alto riesgo, categorías de ambigüedad y destinos	El agente, en cada documento	Versión 0.1
plan_golden.csv	Lista de los documentos de prueba con la respuesta correcta de cada uno	Quien escribe los documentos, y evals/run.py para comparar. El agente nunca lo ve	Listo

Ningún archivo entrena al modelo, y el agente no hace RAG sobre ninguno: consulta dos tablas por búsqueda directa, medicamentos y CIE-10, y lee las reglas.

Cuadros clínicos, medicamentos y códigos

Cada cuadro clínico une las tres tablas: su código CIE-10, los medicamentos que lleva y los documentos del conjunto de prueba que salen de él. Los medicamentos de alto riesgo aparecen en **rojo**.

ID	Cuadro clínico	CIE-10	Prioridad	Medicamentos	Documentos del conjunto de prueba
CC-01	Tromboembolismo pulmonar agudo	I26.9	Urgente	enoxaparina	GS-04, GS-07, GS-25
CC-02	Infarto agudo de miocardio con elevación del ST	I21.9	Urgente	No lleva	GS-18
CC-03	Accidente cerebrovascular isquémico agudo	I63.9	Urgente	No lleva	GS-08
CC-04	Sepsis de foco urinario	A41.9	Urgente	No lleva	GS-14
CC-05	Neumotórax a tensión	J93.0	Urgente	No lleva	GS-09
CC-06	Hemorragia digestiva alta activa	K92.2	Urgente	No lleva	GS-19
CC-07	Hiperpotasemia severa	E87.5	Urgente	No lleva	GS-13
CC-08	Apendicitis aguda complicada	K35.2	Urgente	No lleva	GS-10
CC-09	Nódulo pulmonar sospechoso	R91	Prioritario	No lleva	GS-12, GS-21
CC-10	Anemia ferropénica moderada	D50.9	Prioritario	No lleva	GS-17
CC-11	Diabetes tipo 2 descompensada	E11.9	Prioritario	metformina, insulina glargina	GS-03, GS-23, M2
CC-12	Fractura de radio distal	S52.5	Prioritario	ibuprofeno	GS-22, GS-30
CC-13	Hipertensión arterial en control	I10	Rutina	losartán, amlodipino	GS-01, M1
CC-14	Infección urinaria baja no complicada	N30.0	Rutina	nitrofurantoína	GS-02, M5
CC-15	Lumbalgia mecánica aguda	M54.5	Rutina	ibuprofeno	GS-27, M8
CC-16	Hipotiroidismo primario	E03.9	Rutina	No lleva	GS-15
CC-17	Control prenatal de embarazo normal	Z34.9	Rutina	No lleva	GS-11, GS-29
CC-18	Faringoamigdalitis aguda	J03.9	Rutina	amoxicilina	GS-06, GS-28, M4
CC-19	Reflujo gastroesofágico con esofagitis leve	K21.0	Rutina	omeprazol	GS-20, M7
CC-20	Dislipidemia mixta	E78.5	Rutina	atorvastatina	GS-16, M6
CC-21	Artritis reumatoide	M06.9	Rutina	metotrexato , ácido fólico	GS-05, M3
CC-22	Neumonía adquirida en la comunidad	J18.9	Prioritario	ceftriaxona, amoxicilina-clavulánico	GS-24, GS-26

Once cuadros no llevan medicamentos porque sus documentos son informes, laboratorios u órdenes, que no los incluyen.

El catálogo CIE-10

Usamos la **CIE-10 de la OMS**, la clasificación oficial en Latinoamérica, con códigos de hasta cuatro caracteres. El propio ejemplo del brief usa uno de ellos: I26.9. **cie10.csv** tiene tres columnas, código, descripción y cuadro, con los 22 códigos que usan los cuadros; crece cuando crezca el banco.

Qué falta y contra qué. Los 22 códigos están listos. Lo que falta es el texto que acompaña a cada código: por ejemplo, para I26.9 el archivo dice «Embolia pulmonar sin mención de cor pulmonale agudo». Esos textos se redactaron sin copiarlos de la tabla oficial, así que su redacción puede diferir. Hay que buscar cada código en la tabla de referencia CIE10 de SISPRO, la tabla oficial en español que usa Colombia, basada en la CIE-10 de la OMS, y reemplazar el texto por el oficial. El navegador de la OMS, icd.who.int/browse10, sirve para confirmar que el código existe.

Una regla para el validador: los códigos se comparan sin punto, así I26.9 e I269 son el mismo, y los de tres caracteres como I10 también son válidos.

Los medicamentos

La tabla tiene **22 medicamentos**, de los cuales **11 son de alto riesgo**. Están en dos grupos, y la columna **motivo** dice por qué está cada uno:

1. **14 que aparecen en los documentos del conjunto de prueba.** Cada uno está porque algún documento del plan o alguna receta manuscrita lo usa. Tres de ellos son de alto riesgo: enoxaparina, insulina glargina y metotrexato.
2. **8 de alto riesgo que ningún documento usa:** warfarina, acenocumarol, heparina sódica, alteplasa, morfina, tramadol, fentanilo y cloruro de potasio. Están porque el agente valida las dosis de cualquier receta real, no solo las del conjunto de prueba. En un medicamento de alto riesgo, una dosis fuera de rango tiene que frenarse en revisión antes de llegar a Farmacia. Sin su rango, el sistema solo podría marcarla para auditoría cuando Farmacia ya la tiene.

La cuenta del alto riesgo: 3 del primer grupo más 8 del segundo son 11 medicamentos. En `rules.yaml` aparecen como 13 términos de búsqueda, no porque sean 13 medicamentos, sino porque el cloruro de potasio se puede escribir de tres formas: cloruro de potasio, potasio intravenoso y KCl.

Contra qué se verifican los rangos. Son dosis habituales en adultos, todavía pendientes de verificación, como indica la columna **estado_verificacion**. La referencia única es el prospecto aprobado por la ANMAT, publicado en su Vademécum Nacional de Medicamentos, anmatvademecum.servicios.pami.org.ar: es la fuente oficial y gratuita de los medicamentos comercializados en Argentina, se actualiza de forma permanente y permite descargar el prospecto de cada producto. De ahí se toma la posología para adultos, y en las columnas `producto_consultado` y `fecha_consulta` se anota qué se consultó y cuándo. Se usa una sola autoridad sanitaria para los 22 medicamentos, para que todos los rangos sean comparables. El procedimiento paso a paso está en la sección de pendientes.

Alcance de los rangos. Los rangos funcionan como límites de plausibilidad, no como pautas de dosificación: su objetivo es detectar errores de prescripción evidentes, como una dosis varias veces superior a la habitual o una frecuencia incompatible con el medicamento. Los dos casos de dosis fuera de rango del conjunto de prueba son de este tipo: amoxicilina 5000 mg por toma y metotrexato indicado a diario cuando su pauta es semanal. Por eso la validez del conjunto de prueba no depende de que cada rango esté ajustado al miligramo; la verificación contra la fuente oficial sí es necesaria antes de usar los rangos en producción.

Índice de medicamentos

Cada fila dice por qué el medicamento está en la tabla, con qué término se busca en el Vademécum de la ANMAT y en qué estado está su verificación. Los de alto riesgo aparecen en **rojo**.

ID	Medicamento	Motivo	Buscar en el Vademécum como	Verificación
MED-01	ácido fólico	Conjunto de prueba	ácido fólico	Pendiente
MED-02	amlodipino	Conjunto de prueba	amlodipina	Pendiente
MED-03	amoxicilina	Conjunto de prueba	amoxicilina	Pendiente
MED-04	amoxicilina-clavulánico	Conjunto de prueba	amoxicilina + ácido clavulánico	Pendiente
MED-05	atorvastatina	Conjunto de prueba	atorvastatina	Pendiente
MED-06	ceftriaxona	Conjunto de prueba	ceftriaxona	Pendiente
MED-07	enoxaparina	Conjunto de prueba y alto riesgo	enoxaparina	Pendiente
MED-08	ibuprofeno	Conjunto de prueba	ibuprofeno	Pendiente
MED-09	insulina glargina	Conjunto de prueba y alto riesgo	insulina glargina	Pendiente
MED-10	losartán	Conjunto de prueba	losartán	Pendiente
MED-11	metformina	Conjunto de prueba	metformina	Pendiente
MED-12	metotrexato	Conjunto de prueba y alto riesgo	metotrexato	Pendiente
MED-13	nitrofurantoína	Conjunto de prueba	nitrofurantoína	Pendiente
MED-14	omeprazol	Conjunto de prueba	omeprazol	Pendiente
MED-15	acenocumarol	Alto riesgo: validación de dosis	acenocumarol	Pendiente
MED-16	alteplasa	Alto riesgo: validación de dosis	alteplasa	Pendiente
MED-17	cloruro de potasio	Alto riesgo: validación de dosis	cloruro de potasio	Pendiente
MED-18	fentanilo	Alto riesgo: validación de dosis	fentanilo	Pendiente
MED-19	heparina sódica	Alto riesgo: validación de dosis	heparina sódica	Pendiente
MED-20	morfina	Alto riesgo: validación de dosis	morfina	Pendiente
MED-21	tramadol	Alto riesgo: validación de dosis	tramadol	Pendiente
MED-22	warfarina	Alto riesgo: validación de dosis	warfarina	Pendiente

Medicamentos de alto riesgo

Se alinean con la OMS. Su iniciativa Medication Without Harm señala los medicamentos de alto riesgo como uno de los factores de las situaciones de alto riesgo, y sus seis grupos se resumen con la sigla A PINCH*. La lista de **rules.yaml** es la que decide el alto riesgo, y cada uno de sus medicamentos tiene su fila en la tabla con el rango de dosis. La versión 0.1 cubre cinco de los seis grupos:

Grupo de alto riesgo (A PINCH*)	Términos en rules.yaml	En el conjunto de prueba
Potasio y otros electrolitos	cloruro de potasio, potasio intravenoso, KCl	No
Insulinas	insulina	Sí: GS-03, M2
Narcóticos y sedantes	morfina, tramadol, fentanilo	No
Quimioterápicos e inmunosupresores	metotrexato	Sí: GS-05, M3
Heparina y anticoagulantes	heparina, enoxaparina, warfarina, acenocumarol, alteplasa	Sí: GS-04

* **A PINCH** es la sigla, formada por las iniciales en inglés, con la que se resumen los seis grupos de medicamentos de alto riesgo: **A**ntiinfeciosos, **P**otasio y otros electrolitos, **I**nsulinas, **N**arcóticos y sedantes, quimioterápicos o **C**hemotherapy, e inmunosupresores, y **H**eparina y otros anticoagulantes. El grupo que falta en la tabla, los antiinfeciosos, no se refiere a cualquier antibiótico sino a los de margen terapéutico estrecho, como la gentamicina o la vancomicina, en los que una pequeña diferencia de dosis puede causar daño grave. Ningún cuadro del banco los usa, así que se agregan en una versión posterior. Los antibióticos de nuestros cuadros, como la amoxicilina, la nitrofurantoína o la ceftriaxona, no pertenecen a ese grupo porque su margen es amplio. Fuente de los grupos: OMS, *Medication Safety in High-risk Situations*, 2019.

Cómo se construye cada documento

Los documentos no se buscan: los escribimos nosotros. No existen en ningún lado, y justamente por eso conocemos la respuesta correcta de cada uno. Por cada fila de `plan_golden.csv`:

1. Tomar la fila del plan, por ejemplo GS-06.
2. Leer su cuadro en `banco_clinico.csv`: CC-18, faringoamigdalitis, código J03.9.
3. Escribir el documento con esos datos y con la instrucción de la fila. Se puede hacer a mano con una plantilla o pidiéndoselo a Gemini con la fila y el cuadro en el prompt. Pacientes, médicos y matrículas se inventan.
4. Guardar el texto y, si las columnas lo indican, también el JSON o el PDF, con el ID como nombre: GS-06.txt.
5. Escribir la etiqueta esperada: tipo, datos que deben extraerse, destino, auditoría y categoría. Todo sale de la fila del plan y del texto que se acaba de escribir.

Ejemplo: GS-06, una receta con dosis fuera de rango

CLÍNICA SAN RAFAEL · RECETA MÉDICA

Paciente: Andrea López, 27 años

Diagnóstico: Faringoamigdalitis aguda (J03.9)

Rp/ Amoxicilina 5000 mg vía oral cada 8 horas por 10 días

Dr. Julián Restrepo · MP 88213 · 21/09/2026

Etiqueta esperada: tipo Receta Medica · paciente Andrea López, 27 años · médico Julián Restrepo, matrícula 88213 · amoxicilina 5000 mg cada 8 horas · CIE-10 J03.9 · destino Cola_Revision_Humana · requiere auditoría · categoría AMB-3.

Frases de alarma, solo donde el plan lo indica. En la vida real, muchas epicrisis y recetas cierran con frases como «acudir de urgencia si presenta fiebre» o «consultar a emergencias ante signos de alarma». Esas frases contienen palabras de la lista de urgencias de `rules.yaml`, así que hoy dispararían una alerta a Emergencia. Solo los documentos GS-01, GS-04, GS-24 y GS-25 las incluyen, a propósito, para medir ese efecto de forma aislada. En el resto de los documentos no se escriben.

Qué se revisa en la doble revisión

Dos personas leen cada documento con su etiqueta y revisan cuatro cosas:

1. **Que el documento diga exactamente lo que pide el plan.** Un modelo que genera texto tiende a corregir los errores a propósito: si se le pide 5000 mg puede escribir 500, y si se le pide una orden sin matrícula puede inventarle una. Si eso pasa, el caso deja de probar lo que tenía que probar.
2. **Que no haya errores involuntarios:** una edad que no cuadra, un medicamento que no es del cuadro, una palabra que dispara una urgencia sin querer.
3. **Que la etiqueta coincida con aplicar las reglas a mano:** leer el documento, seguir `rules.yaml` y llegar al mismo destino.
4. **Que los datos esperados coincidan con el texto letra por letra:** nombre, edad, matrícula, dosis y código.

Si las dos personas no coinciden, el documento se corrige antes de entrar al conjunto. Cada revisión se registra con las iniciales de quien revisa en las columnas `revision_1` y `revision_2` del plan. Ningún documento cuenta para las métricas sin las dos revisiones.

Por qué estas cantidades

El conjunto de la versión 0.1 es una **prueba de funcionamiento, no una medición estadística**, y conviene decirlo así si alguien pregunta.

1. **30 documentos** es el mínimo que cubre todo lo que el agente debe distinguir: los seis tipos de documento con al menos cuatro casos cada uno, los cinco resultados posibles con al menos dos casos cada uno y las cinco categorías de ambigüedad. Con menos, algún camino del grafo quedaría sin probar.
2. **12 imágenes degradadas** son tres niveles de legibilidad por cuatro imágenes. Cuatro por nivel es lo mínimo para ver si cada nivel produce su comportamiento esperado: un fallo sobre cuatro ya es visible.
3. **8 recetas manuscritas**, una por integrante del equipo: es la única fuente de letra manuscrita real.

Qué dice un porcentaje con 30 casos. Un porcentaje medido sobre pocos casos tiene un margen de error. Se calcula con la fórmula habitual para proporciones: **margen = $1,96 \times \sqrt{(p \times (1 - p) \div n)}$** , donde p es el porcentaje de acierto, n la cantidad de documentos y 1,96 corresponde a un 95 % de confianza. Si el agente acierta el 90 % de 30 documentos, el margen es de unos 11 puntos ($1,96 \times \sqrt{(0,90 \times 0,10 \div 30)} = 1,96 \times 0,055 = 0,107$). Es decir, con un 95 % de confianza el acierto real está entre el 79 % y el 100 % ($90 - 11 = 79$, y el límite superior no puede pasar de 100). Es una aproximación: con tan pocos casos el margen real es incluso algo mayor, lo que refuerza la conclusión. Alcanza para saber si el sistema funciona o está roto, no para comparar dos versiones que difieren en pocos puntos.

El deber ser. En un producto real el tamaño se calcula al revés, a partir del margen que se necesita: **$n = 1,96^2 \times p \times (1 - p) \div \text{margen}^2$** . Para medir con 5 puntos de margen hacen falta unos 140 documentos ($3,84 \times 0,90 \times 0,10 \div 0,05^2 = 138$), y con 3 puntos, unos 385 ($3,84 \times 0,90 \times 0,10 \div 0,03^2 = 384$). La versión 0.1 prioriza cubrir todos los caminos antes que la precisión estadística, y el conjunto crece en las siguientes versiones.

Los 30 documentos del plan

Cada fila es un documento a escribir. El color del resultado sigue la leyenda del diagrama de decisión del README: verde llega sin auditoría, ámbar llega y además se audita, rojo se detiene en revisión humana.

ID	Tipo	Cuadro	Resultado	AMB	Destino	Formatos	Qué lo distingue
GS-01	Receta	CC-13 Hipertensión	Rutina		Farmacia	Foto leve	Losartán 50 mg cada 24 horas y amlodipino 5 mg cada 24 horas. Cierra con «acudir de urgencia si la presión supera 180/110»: prueba la regla de urgencia por tipo
GS-02	Receta	CC-14 Infección urinaria	Rutina		Farmacia	Foto media	Nitrofurantoína 100 mg cada 6 horas por 5 días
GS-03	Receta	CC-11 Diabetes descompensada	Alto riesgo		Farmacia	Solo texto	Metformina 850 mg cada 12 horas e insulina glargina 12 UI subcutánea nocturna
GS-04	Receta	CC-01 TEP agudo	Alto riesgo		Farmacia	Solo texto	Enoxaparina 80 mg subcutánea cada 12 horas al alta tras un TEP. Menciona el diagnóstico del episodio: prueba la regla de urgencia por tipo
GS-05	Receta	CC-21 Artritis reumatoide	Alto riesgo		Farmacia	Solo texto	Metotrexato 15 mg una vez por semana y ácido fólico 5 mg semanal, bien prescrito
GS-06	Receta	CC-18 Faringoamigdalitis	Ambigüedad	AMB-3	Revisión	Solo texto	Amoxicilina 5000 mg cada 8 horas: dosis fuera de rango
GS-07	Imágenes	CC-01 TEP agudo	Urgencia		Emergencia	PDF · PDF esc. leve	El caso del brief: angiotomografía con tromboembolismo pulmonar agudo
GS-08	Imágenes	CC-03 ACV isquémico	Urgencia		Emergencia	PDF	Tomografía de cráneo con ACV isquémico agudo en ventana terapéutica
GS-09	Imágenes	CC-05 Neumotórax a tensión	Urgencia		Emergencia	PDF	Radiografía de tórax con neumotórax a tensión
GS-10	Imágenes	CC-08 Apendicitis complicada	Urgencia con ambigüedad	AMB-4	Emergencia	PDF	Conclusión legible con peritonitis; el bloque del médico solicitante está cortado
GS-11	Imágenes	CC-17 Control prenatal	Rutina		Historia Clínica	PDF · PDF esc. media	Ecografía obstétrica de 20 semanas sin alteraciones
GS-12	Imágenes	CC-09 Nódulo pulmonar	Rutina		Historia Clínica	PDF · PDF esc. severa	Tomografía con nódulo pulmonar sospechoso, sugiere completar estudio
GS-13	Laboratorio	CC-07 Hiperpotasemia	Urgencia		Emergencia	JSON	Potasio 7,1 mmol/L. También como JSON del sistema de laboratorio
GS-14	Laboratorio	CC-04 Sepsis	Urgencia con ambigüedad	AMB-1	Emergencia	JSON	Laboratorio compatible con sepsis, sin nombre del paciente
GS-15	Laboratorio	CC-16 Hipotiroidismo	Rutina		Historia Clínica	JSON	TSH 9,8 y T4 libre 0,7
GS-16	Laboratorio	CC-20 Dislipidemia	Rutina		Historia Clínica	JSON · Foto severa	Perfil lipídico con LDL 168
GS-17	Laboratorio	CC-10 Anemia ferropénica	Ambigüedad	AMB-2	Revisión	JSON	Paciente de 38 años con fecha de nacimiento de 1961
GS-18	Orden	CC-02 Infarto agudo	Urgencia		Emergencia	JSON	Cateterismo de urgencia por infarto con elevación del ST. También como JSON del sistema del hospital
GS-19	Orden	CC-06 Hemorragia digestiva	Urgencia		Emergencia	PDF	Endoscopia de urgencia por hemorragia digestiva activa
GS-20	Orden	CC-19 Reflujo	Rutina		Autorizaciones	PDF · PDF esc. leve	Endoscopia digestiva alta programada
GS-21	Orden	CC-09 Nódulo pulmonar	Rutina		Autorizaciones	Foto severa	PET-TC de cuerpo entero
GS-22	Orden	CC-12 Fractura de radio	Ambigüedad	AMB-1	Revisión	Solo texto	Reducción e inmovilización de fractura, sin matrícula del médico solicitante
GS-23	Epicrisis	CC-11 Diabetes descompensada	Rutina		Historia Clínica	PDF · PDF esc. media	Internación por hiperglucemia, alta con insulina: prueba que el alto riesgo solo aplica a recetas
GS-24	Epicrisis	CC-22 Neumonía	Rutina		Historia Clínica	PDF · PDF esc. severa	Internación de 4 días por neumonía, alta con amoxicilina-clavulánico. Cierra con «consultar a emergencias ante fiebre o dificultad para respirar»: prueba la regla de urgencia por tipo
GS-25	Epicrisis	CC-01 TEP agudo	Rutina		Historia Clínica	Solo texto	Alta tras TEP tratado, paciente estable. Menciona el diagnóstico del episodio resuelto y cierra con «acudir de urgencia si presenta falta de aire»: prueba la regla de urgencia por tipo
GS-26	Epicrisis	CC-22 Neumonía	Ambigüedad	AMB-4	Revisión	Solo texto	Indicaciones de alta cortadas a la mitad
GS-27	Certificado	CC-15 Lumbalgia	Rutina		Historia Clínica	Foto leve	Tres días de reposo laboral
GS-28	Certificado	CC-18 Faringoamigdalitis	Rutina		Historia Clínica	Foto media	Dos días de reposo
GS-29	Certificado	CC-17 Control prenatal	Ambigüedad	AMB-1	Revisión	Solo texto	Certificado de asistencia a control prenatal, sin nombre del paciente
GS-30	Certificado	CC-12 Fractura de radio	Ambigüedad	AMB-5	Revisión	Solo texto	Certificado de 14 días de reposo y receta de ibuprofeno en el mismo archivo

Las 8 recetas manuscritas del equipo

Una por persona. Cada receta lleva paciente inventado con nombre y edad, médico inventado con matrícula, fecha y firma. Leve: buena luz y papel plano. Media: sombra sobre parte del papel o letra apretada. Severa: foto movida, cortada o muy oscura.

#	Cuadro	Qué escribir	Legibilidad	Resultado esperado
M1	CC-13 Hipertensión	Losartán 50 mg cada 24 horas	Leve	Farmacia
M2	CC-11 Diabetes descompensada	Insulina glargina 12 UI subcutánea nocturna	Leve	Farmacia con auditoría
M3	CC-21 Artritis reumatoide	Metotrexato 15 mg diario. Error a propósito: debe ser semanal	Leve	Revisión, AMB-3
M4	CC-18 Faringoamigdalitis	Amoxicilina 500 mg cada 8 horas por 10 días	Media	Revisión, AMB-4
M5	CC-14 Infección urinaria	Nitrofurantoína 100 mg cada 6 horas por 5 días	Media	Revisión, AMB-4
M6	CC-20 Dislipidemia	Atorvastatina 20 mg cada 24 horas	Media	Revisión, AMB-4
M7	CC-19 Reflujo	Omeprazol 20 mg cada 24 horas por 8 semanas	Severa	Revisión, nueva captura
M8	CC-15 Lumbalgia	Ibuprofeno 400 mg cada 8 horas por 5 días	Severa	Revisión, nueva captura

M2 y M3 son el par más útil: la receta de alto riesgo bien escrita llega a Farmacia con auditoría, y el metotrexato indicado diario en vez de semanal, un error real y conocido, debe frenarse en revisión.

Cómo se etiqueta una imagen degradada

Hereda el contenido del documento del que sale, pero la decisión esperada depende del nivel. **Leve**: la misma que el documento limpio. **Media**: Cola de Revisión Humana con AMB-4. **Severa**: Cola de Revisión Humana pidiendo nueva captura. Por eso GS-07, el caso del brief degradado en leve, debe seguir yendo a Emergencia.

Dos reglas al medir

1. **El camino de score medio no se etiqueta de antemano.** Cuando el score del modelo queda entre 0,60 y 0,85, rules.yaml pide una segunda opinión o agrega una marca de auditoría. Eso depende de la confianza del modelo en cada corrida, así que no puede fijarse en el plan: si un documento de rutina sale con esa marca, no cuenta como error de enrutamiento, cuenta en la tasa de revisión humana.
2. **Los prompts no se ajustan mirando el conjunto de prueba.** Los ejemplos incrustados en los prompts nunca son documentos del conjunto, y cuando un prompt se mejora, se prueba con otros documentos. Si se ajustara mirando los fallos del conjunto, los números dejarían de medir lo que el agente hace con documentos nuevos.

Decisión pendiente: regla de urgencia por tipo de documento

EL EQUIPO DEBE ELEGIR LA OPCIÓN A O LA B ANTES DE ESCRIBIR LOS DOCUMENTOS. Cuatro etiquetas del plan dependen de esta decisión: GS-01, GS-04, GS-24 y GS-25.

	Opción A: regla propuesta, recomendada	Opción B: regla actual de rules.yaml
Informes de estudio, informes de laboratorio y órdenes	Detectan la urgencia las reglas automáticas y el modelo	Detectan la urgencia las reglas automáticas y el modelo
Recetas, epicrisis y certificados	Detecta la urgencia solo el modelo, que lee el contexto y justifica su decisión	Detectan la urgencia las reglas automáticas y el modelo
Qué se gana	Menos falsas alarmas: una receta o una epicrisis que menciona un diagnóstico ya tratado, o que cierra con «acudir de urgencia si...», sigue su destino normal	Máxima sensibilidad: cualquier palabra de las listas manda el documento a Emergencia, sea del tipo que sea
Qué se arriesga	Si el modelo no reconoce una urgencia real en una receta, una epicrisis o un certificado, no hay una lista automática que la atrape. Es poco frecuente, porque esos documentos rara vez comunican una urgencia activa	Falsas alarmas: cada alta que menciona un diagnóstico grave o cierra con una frase de alarma va a Emergencia, y la guardia aprende a ignorar las alertas
Etiqueta esperada de GS-01, GS-04, GS-24 y GS-25	Su destino normal: Farmacia o Historia Clínica	Emergencia

Recomendación: opción A. Las listas asumen que una palabra indica una urgencia activa, y eso solo es cierto en los documentos que comunican un hallazgo nuevo o piden atención.

Qué son las reglas automáticas. Son listas fijas de rules.yaml, no rangos. La lista de hallazgos críticos, como «tromboembolismo pulmonar», y la de palabras de urgencia, como «de urgencia» o «emergencia», disparan con que la palabra aparezca en el texto. Los valores críticos de laboratorio, como un potasio de 6,5 o más, sí son umbrales, pero solo existen en informes de laboratorio y funcionan igual con las dos opciones. En la práctica, la decisión es en qué documentos se aplican las dos listas de palabras.

Ejemplo. La epicrisis de un paciente dado de alta tras un tromboembolismo pulmonar menciona el diagnóstico y cierra con «acudir de urgencia si presenta falta de aire». Con la opción B, las dos frases la mandan a Emergencia aunque el paciente ya fue tratado y se fue a su casa. Con la opción A, el modelo reconoce que es un alta y el documento va a Historia Clínica.

Las fuentes públicas: para qué sirven y cuándo se usan

CodiEsp, MEDDOCAN y PharmaCoNER son casos clínicos publicados en revistas médicas, en español, anotados por especialistas y con licencia CC BY 4.0. **En la versión 0.1 no se usan:** el conjunto de prueba de esta versión son los 30 documentos del plan, las 12 imágenes y las 8 recetas manuscritas. Tampoco sirven para dar formato a las recetas, porque son textos narrativos y no contienen recetas.

Fuente	Qué aporta	Para qué se usará
CodiEsp	Casos con códigos CIE-10 asignados por expertos	Medir si el código que sugiere el agente es correcto
MEDDOCAN	Casos con nombres de paciente y profesional, fechas e identificadores anotados	Medir si el agente extrae bien esos datos
PharmaCoNER	Casos con los medicamentos anotados por farmacólogos	Medir si el agente encuentra los medicamentos

Cada uno mide un solo campo contra la anotación de un experto: es la parte de la evaluación con datos clínicos reales. Se incorporan en la siguiente versión, cuando el conjunto de prueba funcione de punta a punta, porque hay que adaptar sus formatos de anotación.

Idea para la siguiente iteración: documentos basados en casos reales

Además de medir campos, los casos de CodiEsp pueden servir como **base de los informes y las epicrisis**, que son los tipos más parecidos a un caso clínico. Se toma un caso real y se reescribe en el formato del documento. Eso aporta lenguaje clínico auténtico, hallazgos reales y un código CIE-10 asignado por un experto, y la licencia permite adaptarlos citando la fuente.

Funciona mejor en los cuadros graves, como TEP, infarto, ACV, sepsis, apendicitis o neumonía, porque las revistas publican casos serios; una lumbalgia o un control prenatal casi nunca aparecen, así que esos se siguen escribiendo.

Cómo se haría. Un script busca en el corpus los términos de cada cuadro y lista los casos candidatos. Por cada informe urgente o epicrisis del plan se elige un caso, se reescribe en el formato del documento y se le aplica la instrucción de la fila, por ejemplo quitar el nombre del paciente. El plan suma una columna con el identificador del caso para citarlo. Alcance estimado: entre 8 y 10 de los 30 documentos.

Una precaución. CodiEsp codifica con la modificación clínica de la CIE-10, que tiene códigos más largos que los de la OMS. Al usarlo para medir el código sugerido, la comparación se hace por categoría, los tres primeros caracteres como I26 o E11, que las dos clasificaciones comparten.

Pendientes y cómo hacerlos

En orden. Cada pendiente dice cómo se hace, dónde queda registrado y cuándo se da por terminado.

#	Pendiente	Cómo se hace	Queda registrado en	Listo cuando
1	Decidir la regla de urgencia por tipo de documento	Elegir la opción A o la B de la sección Decisión pendiente. Con la A, se agrega a rules.yaml la lista de tipos donde aplican las reglas automáticas. Con la B, GS-01, GS-04, GS-24 y GS-25 pasan a esperar urgencia en el plan	rules.yaml, docs/decisions.md y el diagrama del README	La opción elegida está escrita, las cuatro etiquetas la reflejan y el diagrama la muestra
2	Verificar los rangos de los 22 medicamentos	Con el procedimiento de abajo, empezando por los 11 de alto riesgo	medicamentos.csv: producto_consultado, fecha_consulta y estado_verificacion	Las 22 filas están en estado verificado
3	Revisar las 22 descripciones del catálogo CIE-10	Comparar cada descripción de cie10.csv con la de la tabla de referencia CIE10 de SISPRO y reemplazarla por el texto oficial. Confirmar el código en icd.who.int/browse10	cie10.csv	Las 22 descripciones coinciden con la fuente oficial
4	Escribir los 30 documentos del plan	Fila por fila, como explica la sección Cómo se construye cada documento: a mano con una plantilla o con Gemini	Un archivo por documento con su ID como nombre, más su etiqueta esperada	Existen los 30 textos, los 6 JSON y los 10 PDF que pide el plan
5	Doble revisión	Dos personas leen cada documento con su etiqueta y comprueban los cuatro puntos de la sección de revisión	plan_golden.csv: revision_1 y revision_2, con iniciales	Los 30 documentos tienen las dos revisiones y ninguna discrepancia abierta
6	Degradar las 12 imágenes	Correr el script de Augraphy sobre los documentos marcados en la columna variante_imagen, con el nivel de la columna nivel_legibilidad	Un archivo por imagen, con el ID y el nivel en el nombre	Existen las 12 imágenes: 4 leves, 4 medias y 4 severas
7	Recetas manuscritas	Cada persona escribe y fotografía la receta asignada según la tabla de las recetas manuscritas	Una foto por receta: M1.jpg a M8.jpg	Existen las 8 fotos con la legibilidad pedida
8	Validar el formato	Correr evals/run.py contra el flujo simulado	El informe de la corrida	La corrida termina sin errores de formato

Procedimiento para verificar un medicamento

1. Entrar al Vademécum Nacional de Medicamentos de la ANMAT: anmatvademecum.servicios.pami.org.ar.
2. Buscar por principio activo, con el término exacto de la columna buscar_en_vnm.
3. En la lista de resultados, abrir la ficha de un producto que se comercialice y descargar su prospecto.
4. En la sección de posología del prospecto, tomar la pauta para adultos: dosis mínima y máxima por toma, frecuencia y dosis máxima diaria. Si el prospecto indica la dosis por kilo de peso o por hora, como en la alteplasa o la heparina sódica, se registra de esa forma y se aclara la unidad en notas.
5. Comparar con la fila de medicamentos.csv. Si hay diferencia, se corrige la fila con el valor del prospecto.
6. Completar producto_consultado con el nombre comercial y el laboratorio, y fecha_consulta con la fecha. Cambiar estado_verificacion a verificado.
7. Si el principio activo no aparece en el Vademécum, se anota no comercializado en Argentina y se verifica con el prospecto aprobado por INVIMA, dejando constancia en notas.

Para la siguiente versión

Pendiente	Qué implica
Evaluación de campos con las fuentes públicas	Medir el código CIE-10 con CodiEsp, paciente y profesional con MEDDOCAN, y medicamentos con PharmaCoNER, contra anotaciones de expertos
Casos para potasio, narcóticos y antiinfecciosos de margen estrecho	Potasio y narcóticos ya tienen su fila en la tabla, así que el validador los cubre, pero falta un caso que lo pruebe. Los antiinfecciosos de margen estrecho, como la gentamicina o la vancomicina, además necesitan sus términos en rules.yaml y sus filas en la tabla. El patrón sí está probado con M3: un medicamento de alto riesgo con un error de dosis que debe frenarse en revisión
Documentos basados en casos reales	La idea de la sección de fuentes públicas: entre 8 y 10 informes y epicrisis reescritos a partir de casos clínicos publicados